聚酯家族高分子结晶数据库项目详解

背景·意义·数据模型·技术流程·工程要点·运行手册·展望

葛陆熠　朱芷卿　指导教师：胡文兵

南京大学匡亚明学院 / 化学化工学院，南京 210023

代码仓库：https://github.com/gly66666666/polyester-crystal-db

2026 年 10 月

摘要

本文是「AI 驱动的高分子结晶数据库构建与智能检索系统」项目的完整技术说明，面向项目成员本人、指导教师与后续接手者。内容覆盖：选题背景与科学意义、研究范围与「一条数据」的口径定义、四层数据模型、LLM 抽取流水线的完整流程、工程实现中真实踩过的坑（DOI 核验、单位换算、幂等重跑、API 错误分类、合规红线）、当前实测进展（开放获取可获取性、Gold Set 基准、主库状态）、可复现的运行手册，以及后续展望。文末给出合规红线速查表与模块清单。

与学术论文的分工：本文是「工程与操作文档」，`paper/main.tex` 是「研究论文」；两者共享同一套数据与方法，但本文包含大量实现细节与内部约定，不作为投稿内容。

目录

1 项目速览 **3**

2 科学背景与研究意义 **3**

2.1 高分子结晶为什么重要 . . . 3

2.2 现有数据资源的缺口 . . . 4

2.3 本项目的意义 . . . 4

3 研究范围与数据口径 **4**

3.1 聚酯家族成员 . . . 4

3.2 「一条数据」的口径 . . . 4

4 四层数据模型 **5**

4.1 单位约定（必须遵守） . . . 6

5 技术流程 **6**

5.1 阶段一：文献检索与语料装配 . . . 6

5.2 阶段二：LLM 抽取（输出合约） . . . 7

5.3 阶段三：归一化、sanity 与冲突消解 . . . 7

5.4 阶段四：落库与溯源 7
5.5 阶段五：Gold Set 与评测 7

6 工程实现要点（真实踩过的坑） 7
6.1 DOI 必须机器核验 7
6.2 幂等与断点续跑 7
6.3 API 错误处理（429 要分类） 8
6.4 稳健离群检测 8
6.5 合规与版权 8

7 当前进展与实测数据 8
7.1 开放获取可获取性实测 8
7.2 Gold Set 基准：20 条权威晶胞 9
7.3 流水线贯通验证 9

8 如何运行下去（操作手册） 10
8.1 前置条件 10
8.2 常用命令 10
8.3 验收指标 11

9 展望 11

10 合规红线速查 11

A 模块一览 11

1 项目速览

一句话概括

用大语言模型从高分子结晶文献中**自动抽取**晶体结构与热/动力学实测数据，建成一个**可回溯、可复核、单位统一**的聚酯家族结晶数据库，并用人工核验的 **Gold Set** 基准来量化抽取质量。

- **性质**：南京大学「金种子」早期科研训练项目。
- **周期**：2026.05 – 2027.05。
- **范围**：半结晶性**聚酯家族**（先做 4 个成员，规划 12 个 Tier1），不是「所有高分子」，也不是「单一聚合物」——是**一类**。
- **目标规模**：≥ 300 **条** L2 观测行。
- **当前状态**：数据模型 + 抽取流水线 + 评测框架已代码完备并贯通验证；Gold Set 20 条已预填并落库；**真实抽取待密钥与全文 PDF**。

仓库与目录

```
https://github.com/gly66666666/polyester-crystal-db

polyester-crystal-db/
  data/          # 数据（gold_set / literature / processed / polymer_crystal.db）
  src/annotation/# 文献检索、引文核验、OA 实测、Gold Set 标注
  src/database/  # schema.sql + init_db.py
  src/extraction/# 抽取流水线（corpus/extractor/llm_client/normalizer/store/evaluate/...
  )
  paper/         # 研究论文 LaTeX
  docs/          # 工程文档（本文、全文获取、Gold Set 策展）
```

2 科学背景与研究意义

2.1 高分子结晶为什么重要

半结晶性高分子的性能（力学强度、阻隔性、耐热性、降解速率）几乎全部由**凝聚态结构**决定，而不仅仅是化学组成。关键结构量包括：

- **晶胞参数**（$a, b, c, \alpha, \beta, \gamma$、空间群、$Z$、晶体密度 ρ_c）；
- **晶型**（如 PBT 的 α 与 β 型、PLLA 的 $\alpha/\beta/\gamma/\alpha'$）；
- **热力学量**（平衡熔点 T_m^0、熔融焓 ΔH_f、玻璃化温度 T_g）；
- **动力学量**（结晶温度 T_c、Avrami 指数 n、球晶生长速率）；

- **形态量**（SAXS 长周期、片晶厚度、结晶度）。

这些量**强依赖热历史**：同一聚合物在不同 T_c、降温速率、拉伸比下会得到不同晶型与不同结晶度。因此「某聚合物的熔点是多少」这个问题本身不严谨——必须**连同测量条件一起记录**。这正是本项目把「一条数据」定义为「一个 T_c / 一组结构」的根本原因。

2.2 现有数据资源的缺口

- **小分子晶体学有成熟开放库**（COD、CCDC、ICSD），但**高分子没有对应的开放晶体学数据库**：晶胞参数散落在数十年文献的表格里，没有统一单位、没有统一热历史记录。
- **PoLyInfo**（日本 NIMS）是目前最完整的聚合物数据库，但为**注册制、闭源**，数据不可再分发。本项目**仅可用于交叉校验，绝不可入库**。
- 文献中的晶胞参数**几乎只出现在全文表格**里，摘要通常不含——这决定了自动化的最大瓶颈是**全文获取**（见第 7.1 节实测）。

2.3 本项目的意义

1. **数据层面**：把散落的聚酯家族结晶数据聚成结构化、单位统一、可回溯单一 DOI 的数据集，填补「一类高分子」的开放数据空白。
2. **方法层面**：给出一套**可复用**的 LLM 抽取 + 质量治理流水线（单位归一、越界标记、冲突保留、人工复核队列、Gold Set 评测），这套方法论对其它材料体系同样适用。
3. **可信度层面**：以「宁可 null 不许编」为硬约束，用 Gold Set 给出**量化的**抽取准确率，而不是宣称「AI 抽得很准」。
4. **训练层面**：作为本科早期科研训练，覆盖文献计量、数据库设计、LLM 工程、合规与版权意识等完整科研链条。

3 研究范围与数据口径

3.1 聚酯家族成员

当前 Gold Set 与流水线验证**聚焦 PET / PTT / PBT / PLA 四个成员**（PLA 取 PLLA），其余 8 个成员已在 `polymers` 表（L0）建好槽位，待规模化时填充。

3.2 「一条数据」的口径

核心约定

一条 = 一个 L2 观测行 = 一个 T_c（或一组测量条件）下的一组结构/物性观测。晶胞参数本身**不属于** L2，而是上提到 L1（晶型层），L2 通过 `polymorph_id` 外键引用。

这样设计的理由：同一晶型（如 PET 三斜 α）在不同文献/不同条件下会被反复观测；若把晶胞塞进每一条观测，既冗余又会因「同一晶型不同文献给出略不同晶胞」而产生假冲突。把晶胞放在 L1、观测放在 L2，才能干净地表达「同一晶型 + 多次观测」以及「同晶型的晶胞分歧」。

表 1: Tier1 必收的 12 个半结晶性聚酯家族成员

缩写	类别	英文名称
PET	芳香族	Poly(ethylene terephthalate)
PBT	芳香族	Poly(butylene terephthalate)
PTT	芳香族	Poly(trimethylene terephthalate)
PEN	芳香族	Poly(ethylene naphthalate)
PBN	芳香族	Poly(butylene naphthalate)
PLA	脂肪族	Poly(lactic acid)
PGA	脂肪族	Poly(glycolic acid)
PCL	脂肪族	Poly(ε-caprolactone)
PBS	脂肪族	Poly(butylene succinate)
PBSA	脂肪族	Poly(butylene succinate-co-adipate)
PHB	脂肪族	Poly(hydroxybutyrate)
PHBV	脂肪族	Poly(hydroxybutyrate-co-valerate)

4 四层数据模型

表 2: 四层模型（含 L2.5 扩展层）的职责划分

层	表名	职责 / 典型字段
L0	`polymers`	家族成员：缩写、中英文名、重复单元 SMILES、分子量、手性、Tier
L1	`polymorphs`	晶型：晶胞 $a, b, c, \alpha, \beta, \gamma$、空间群、$Z$、$\rho_c$、纤维周期、链构象、螺旋类型
L2	`observations`	实测观测：DOI/年/期刊/表号、热历史 (T_c、降温速率、退火、拉伸比)、结晶度、$T_m/T_m^0/\Delta H_f/T_g$、Avrami、生长速率
L2.5	`atomic_coordinates` / `properties`	原子坐标（高分子 CIF 罕见，预留）；`properties` 存放 L2 未列的其它实测值**及被判定为分歧而保留的晶胞值**
L3	`literature_sources`	文献来源与抽取溯源：DOI（唯一）、题录、抽取模型版本、抽取时间、数值片段

表 3: 入库值的规范单位

量	规范单位	量	规范单位
a, b, c, 纤维周期	Å	T_c, T_m, T_m^0, T_g, 退火温度	°C
α, β, γ	°	ΔH_f	J/g
ρ_c	g/cm^3	生长速率	nm/s
长周期 / 片晶厚度	nm	$t_{1/2}$ / 退火时间	min / h
结晶度	%	M_w, M_n	g/mol

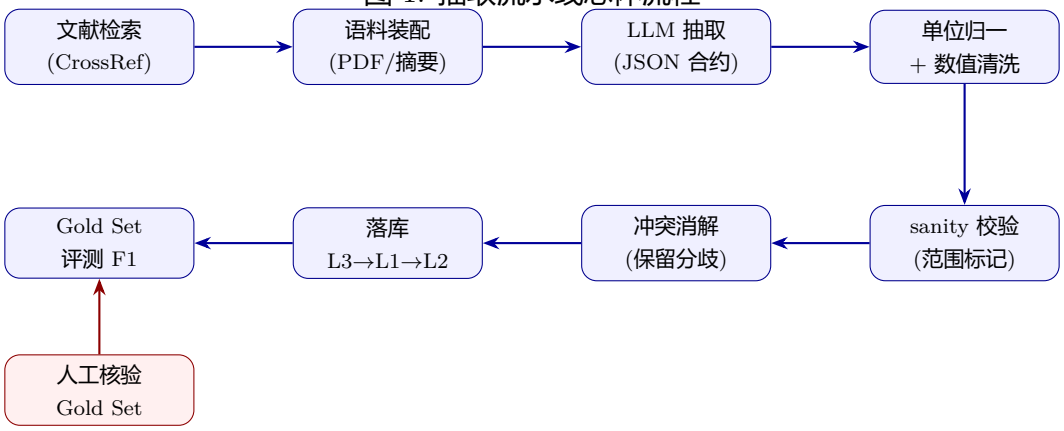
4.1 单位约定（必须遵守）

单位换算的三个陷阱（真实踩过）

1. ΔH_f：**kJ/mol → J/g 必须除以重复单元分子量 MW**（$\Delta H_f[\mathrm{J/g}] = \Delta H_f[\mathrm{kJ/mol}] \times 1000/\mathrm{MW}$）。忘记这一步会得到差 1–2 个数量级的值，是本项目**最容易出现的系统性错误**。`units.py` 在缺 MW 时会**拒绝换算并置空**，而不是猜。
2. **K → °C 是偏移而非比例**（-273.15）；°F 需 $(v-32)\times 5/9$。写成乘法会得到荒谬结果。
3. **nm 与 Å 差 10 倍**：晶胞用 Å，而 SAXS 长周期常用 nm，两者极易混。

5 技术流程

图 1: 抽取流水线总体流程



5.1 阶段一：文献检索与语料装配

- 通过 CrossRef 检索各成员的候选文献，结果存 `data/literature/search_results.json`。
- `corpus.py` 把检索结果装配成 `job`：**优先**读取本地 PDF(`data/literature/<DOI 消毒名 >.pdf`，pdfplumber 提取全文)，**无 PDF 时用 CrossRef 摘要兜底。**
- 摘要兜底只能抽到部分热/动力学量；**晶胞基本抽不到**——这是全流程最大瓶颈。

5.2 阶段二：LLM 抽取（输出合约）

当前实现为**单次调用 + 严格 JSON 合约**（response_format=json_object，温度 0）。合约字段用**后缀固定单位**（_A=Å、_deg=°、_celsius=°C、_jg=J/g、_nms=nm/s 等），再由 FIELD_MAP 映射到 schema 列名。

三条硬规则（写进 system prompt）

1. **宁可 null 不许编**：拿不准的数值填 null 并列入 unknown_fields，禁止插值或猜测。
2. **置信度必须自评**：confidence < 0.7 视为不可信，**强制进入人工复核队列。**
3. **每条必须能回溯**：evidence 写清表号/图号（≤ 200 字符），不得大段复制原文。

5.3 阶段三：归一化、sanity 与冲突消解

- normalizer.py：数值清洗 + 范围 sanity（**只标记不拦截**，保留全部记录）+ 按置信度分流（auto / pending_review），并把结构字段拆到 L1、实测拆到 L2。
- store.py 的**冲突消解（§4.4 规则 1）**：L1 按（polymer_id，polymorph_label）去重，若后来文献给出的晶胞相对既有值偏差 $> 2\%$（DIVERGE_TOL），**不覆盖、不删除**，而是把分歧值写入 properties 并置 conflict_flag=1——「分歧记录本身就是本项目的数据价值」。

5.4 阶段四：落库与溯源

写入顺序 L3 $\rightarrow$ L1 $\rightarrow$ L2：literature_sources 按 DOI upsert（记录抽取模型版本与时间）；polymorphs find-or-create；observations 按（doi，polymer，polymorph，T_c）**幂等去重。**

5.5 阶段五：Gold Set 与评测

evaluate.py 按（polymer_abbr，doi）匹配 Gold Set 与抽取结果，逐数值字段算 P/R/F1（相对误差 $\leq 2\%$ 视为命中），微平均 F1 与 **P1 验收线 80%** 比对。Gold 未标注的字段**不计入**（避免惩罚抽取出的额外正确数据）。

6 工程实现要点（真实踩过的坑）

6.1 DOI 必须机器核验

血泪教训

凭记忆写的「经典文献」DOI **全部错误**（4/4 错，例如 PET 的某个 DOI 实为另一篇无关论文）。**任何 DOI 写入代码/数据前，必须经 CrossRef API 核验题录**：https://api.crossref.org/works/<DOI>。型号、人名、卷期页的记忆都不可靠。

6.2 幂等与断点续跑

- **落库幂等**：同（doi，polymer，polymorph，T_c）已存在则跳过，避免重复跑批产生脏数据。

- **checkpoint**：已处理 DOI 落盘 `data/processed/extraction_checkpoint.json`，可 `--resume` 断点续跑，**避免重复调 API 花钱。**
- **Gold Set 重导幂等**：`export-db` 先清旧 `gold` 行再插入，改完 gold 可安全重导而不会累积重复。

6.3 API 错误处理（429 要分类）

- `429 rate_limit_exceeded` → **指数退避重试。**
- `429 quota_exceeded` → **不重试**，直接抛错并提示补额度。
- `401/403/404`、参数错误 → **不重试**（检查 Key / 模型 ID / 路径）。
- `5xx` / 网络层错误 → 有限次退避重试。
- 非流式；流式一旦吐字不重试（本项目用非流式即可）。

6.4 稳健离群检测

用**中位数 + MAD**（MAD 乘以 1.4826）而非均值 ± 标准差——后者本身会被离群值污染。配合 sanity 区间宽松标记（**只标记不删**）。

6.5 合规与版权

- **PoLyInfo 仅交叉校验，绝不可入库**（NIMS 版权 + 注册制）。
- 只存**数值性事实 + 出处定位**，不整段复制原文、不复制图表。
- PDF **已 gitignore，不入库不分发**；CIF 原始抓取目录同样排除。
- 每条抽取值**必须可回溯单一 DOI**；无 DOI 不入库。

7 当前进展与实测数据

7.1 开放获取可获取性实测

对 60 条候选文献做分层抽样实测**「是否真能自动下载到 PDF」**，而非只看 Unpaywall 的 `is_oa` 标记：

表 4: 全文可获取性实测（$N = 60$）

状态	条数	占比	含义
closed	49	81.7%	完全封闭，需订阅/馆际互借
oa_landing	9	15.0%	标为 OA 但只有落地页，需浏览器会话，**脚本下不到**
oa_pdf	2	3.3%	确有直链可自动下载 PDF

结论：不要把 `is_oa` 当作「可自动获取」

`is_oa` 会把「只有落地页」也算作开放，**高估自动化获取能力约 5.5 倍。**真实可自动下载 PDF 的仅 **3.3%**。自动抓取**无法**支撑规模化（需 ≥ 300 条）；必须走**学校图书馆订阅 / 馆际互借 / 人工下载 PDF。**

7.2 Gold Set 基准：20 条权威晶胞

Gold Set 20 条（PET/PTT/PBT/PLA 各 5 条）已预填，数值取自 CrossRef 核验过的**经典结构文献**：

表 5: 四成员的权威晶胞与热力学参考值（预填，待人工复核）

成员	晶系 / 空间群	a Å	b Å	c Å	α °	β °	γ °	ρ_c g/cm^3
PET	三斜 / $P\bar{1}$	4.56	5.94	10.75	98.5	118.0	112.0	1.455
PBT	三斜 / $P1$ (α)	4.83	5.94	11.59	99.7	115.2	110.8	1.40
PTT	三斜 / $P\bar{1}$	4.64	6.22	18.64	98.4	93.0	111.5	1.43
PLLA	正交 / $P2_12_12_1$ (α)	10.68	6.17	28.86	90	90	90	1.29

表 6: 对应热力学量与来源 DOI

成员	T_m °C	T_m^0 °C	T_g °C	ΔH_f J/g	来源 DOI
PET	256	–	80	140	`10.1098/rspa.1954.0273`
PBT	223	–	45	140	`10.1002/pol.1975.180131109`
PTT	228	237	40	–	`10.1016/0032-3861(79)90064-8`
PLLA	175	–	60	93	`10.1021/ma001630o`

- 校验：`validate` **0 问题**，20/20 全填。
- 状态：`confidence=medium`，`notes` 标注「自动预填·需人工复核」；`ref_table`（表/图号）**仍为空**，需打开原文补。
- 主库：`observations` 已写入 **20 条 gold**，`polymorphs` **4 条**（每成员一个 α 晶型）。
- 落库时把预填标记带入（`reviewed_by='auto-pre-fill'`、`extraction_confidence=0.5`），**避免未核验预填被误当最终真值。**

7.3 流水线贯通验证

无需密钥即可用 `mock` 后端跑通全链路（已实测 5 篇，全部正确产出）：

```
python -m src.extraction.pipeline --backend mock --limit 5 --dry-run \
       --out data/processed/extraction_output_mock.json
# -> 处理 5 篇 | 解析失败 0 | 置信>=0.7(auto) 0 | 待人工复核 5
```

mock 后端置信度固定 $0.6 < 0.7$，因此全部进入 `pending_review`，正好验证了「低置信强制进人工复核队列」的逻辑。

已发现的关键缺口：基准对齐

`evaluate.py` 按 `(polymer, doi)` 匹配，但当前 Gold Set 每成员 5 条**共用同一个经典 DOI**（共 4 个 DOI），导致 (a) 与真实抽取产出的文献 DOI 对不上，**实测匹配 0 条**；(b) `_load_gold` 按 DOI 建索引会把同 DOI 的 5 条**压成 1 条**。

- 当前 Gold Set 实质是「经典值知识库」，**尚不是**「20 篇文档的基准」。
- 修复方向：给 20 条各分配一个**独立且确为均聚物晶体**的真实 DOI，并从**对应论文**填值，使 `(polymer, doi)` 能与抽取结果对齐。

8 如何运行下去（操作手册）

8.1 前置条件

1. Python 依赖：`pip install -r requirements.txt`（pdfplumber 等）。
2. **真实抽取**需环境变量 `TOKENPLAN_API_KEY`
   （墨点计划 OpenAI 兼容接口，默认模型 `deepseek-v4-flash-0731`）。
   无密钥时只能用 `mock` 后端跑框架自测。
3. **晶胞抽取**需把 PDF 全文放到
   `data/literature/<DOI 消毒名 >.pdf`
   （命名与 `corpus.pdf_path_for` 一致：非字母数字换成下划线）。

8.2 常用命令

```
# --- Gold Set ---
python src/annotation/gold_set_annotator.py stats      # 覆盖情况
python src/annotation/gold_set_annotator.py validate   # 校验（0 问题才可用）
python src/annotation/gold_set_annotator.py export-db  # 幂等写入主库（gold）

# --- 流水线：先 mock 自测（无需密钥）---
python -m src.extraction.pipeline --backend mock --limit 10 --dry-run

# --- 流水线：真实抽取（需密钥 + PDF）---
export TOKENPLAN_API_KEY=<你的密钥>
python -m src.extraction.pipeline --backend tokenplan \
       --polymers PET,PBT,PTT,PLA --resume

# --- 评测 ---
python -m src.extraction.evaluate \
       --extracted data/processed/extraction_output.json --tol 0.02
```

```
# --- 论文编译（需两遍）---
cd paper && xelatex -interaction=nonstopmode main.tex && xelatex -interaction=
  nonstopmode main.tex
```

8.3 验收指标

P1 验收：字段级 F1 $\geq 80\%$**。未达标则不进入规模化**，需提高人工复核比例或改进 prompt。

9 展望

1. **规模化到** ≥ 300 **条**：先把 12 个 Tier1 成员全部铺开，重点解决全文获取（图书馆订阅 / 馆际互借）。
2. **把 Gold Set 变成真正的 20-文档基准**：补齐独立 DOI 与 `ref_table`，让 `evaluate` 真正跑出可信 F1。
3. **改进抽取**：在当前单轮 JSON 合约基础上探索**两阶段**（先定位候选表/图，再精抽数值），提升晶胞抽取召回。
4. **补 L2.5**：接入原子坐标（若有高分子 CIF）与更多物性（`properties`）。
5. **检索与可视化前端**：把四层模型暴露为查询接口，支持「按聚合物 + 晶型 + T_c 区间」检索与冲突可视化。
6. **交付**：中文核心期刊论文（结题硬交付）+ 后续英文投稿（锁定**非 OA** 免/低版面费期刊，OA 版面费约 1.8 万元超预算）。

10 合规红线速查

红线	说明
单一 DOI 可回溯	每个抽取值必须挂单一 DOI；无 DOI 不入库
DOI 必机器核验	写库前经 CrossRef 核验题录，禁止凭记忆写 DOI
PoLyInfo 不入库	仅作交叉校验，NIMS 版权 + 注册制
不复制原文	只存数值性事实 + 表/图号定位，不整段复制、不复制图表
PDF 不入库	`.gitignore` 已排除，不分发受版权全文
金标准须人工	Gold Set 数值必须由人工打开原文核验；脚本只能填书目，**不得臆测晶胞/热力学数值**

A 模块一览

模块	职责
src/database/schema.sql	四层表结构与单位注释（v1.1）
src/database/init_db.py	建库与 12 个 Tier1 成员初始化
src/annotation/shortlist.py	文献候选排序（已覆盖 12 成员同义词）
src/annotation/verify_refs.py	CrossRef DOI 题录核验
src/annotation/oa_survey.py	开放获取可获取性分层实测
src/annotation/gold_set_annotator.py	Gold Set 标注、校验、幂等落库、基准对比
src/annotation/fill_gold_set_prefill.py	Gold Set 经典值预填
src/annotation/repoint_offtopic_dois.py	off-topic 记录 DOI 改挂
src/extraction/corpus.py	语料装配（PDF 优先，摘要兜底）
src/extraction/extractor.py	调 LLM + 解析 JSON + 映射 schema 列名
src/extraction/llm_client.py	backends: mock / tokenplan（429 分类、退避）
src/extraction/normalizer.py	单位归一、清洗、sanity、置信分流、L1/L2 拆分
src/extraction/units.py	单位换算（含 kJ/mol→J/g 需 MW）
src/extraction/store.py	落库（L3→L1→L2）、去重、冲突消解
src/extraction/pipeline.py	编排 + checkpoint + dry-run
src/extraction/evaluate.py	与 Gold Set 对比，字段级 P/R/F1