面向聚酯家族的高分子结晶数据库构建：四层数据模型、LLM 抽取流水线与数据质量治理

葛陆熠[1]　朱芷卿[1]　胡文兵[2,*]

[1]南京大学匡亚明学院，南京 210023

[2]南京大学化学化工学院高分子科学与工程系，南京 210023

* 通讯作者，E-mail: wbhu@nju.edu.cn

摘要

摘　要　半结晶性高分子的结晶结构与其热历史、加工条件强耦合，同一聚合物在不同结晶温度、拉伸与退火条件下可给出晶型、晶胞参数与热力学量的系统性差异。这类数据目前以表格形式散落在数十年的期刊文献中，既无统一的结构化表示，也缺乏可回溯的出处记录，因而难以支撑统计分析与数据驱动的建模。本文面向**半结晶性聚酯家族**（PET、PBT、PTT、PEN、PBN、PLA、PCL、PGA、PBS、PBSA、PHB、PHBV 共 12 个成员），提出并实现一个” 文献检索 → 大语言模型抽取 → 结构化归一 → 质量治理 → 入库检索” 的完整技术路线。主要工作包括：(1) 提出聚合物–晶型–观测–文献四层数据模型（L0–L3），把晶胞参数归入晶型层 (L1)、把实测条件与热力学量归入观测层（L2），使” 一条记录 = 一组结晶条件下的一组结构/性质” 成为可计数的建模单元；(2) 实现一条具备幂等落库、断点续跑、置信自评与出处定位的抽取流水线，并针对高分子文献特有的单位陷阱（如 kJ/mol 与 J/g 的换算依赖重复单元分子量）建立归一化模块；(3) 建立” 保留全部分歧 + 互相标记冲突 + 择优排序外置” 的冲突消解机制，把文献间数值不一致从” 需要消除的错误” 转化为” 可分析的数据资产”；(4) 以开放获取可获取性实测为例，给出自动化文献获取在本领域的真实上限：在 12 个成员分层抽样的 60 条高相关候选中，Unpaywall 判定为开放获取的比例为 18.3%，但其中可由程序直接下载全文 PDF 的仅 3.3%（2/60），说明规模化数据建设必须依托机构订阅与人工核验，而不能依赖自动抓取。本文所有数据条目强制绑定单一 DOI 并以” 仅存数值性事实 + 出处定位” 为合规边界，不整段复制原文、不复制图表、不转载受许可约束的晶体学文件。文中给出了检索覆盖、系统实现与可获取性实测的定量结果，抽取精度评测因人工金标准标注尚未完成而以**占位表**形式给出，未在本文填入任何未经实测的数值。

关键词：高分子结晶；聚酯；数据库；大语言模型；信息抽取；数据质量；可溯源数据

中图分类号：O631　**文献标识码：**A

目录

1 引言 **3**

1.1 问题的由来：结晶数据” 可查” 但” 不可用” 3

1.2 为什么是” 一类高分子”，而不是” 所有高分子” 或” 单一聚合物” 3

1.3 本文的贡献与边界 3

2 相关工作 **4**
2.1 通用材料数据库：晶体学与计算数据 4
2.2 聚合物数据库：PoLyInfo 与其可复用性 4
2.3 文献信息抽取：从规则工具到大语言模型 5

3 四层数据模型 **5**
3.1 分层原则 5
3.2 计数口径：一条 = 一个观测行 6
3.3 溯源是硬约束 6

4 系统与方法 **6**
4.1 总体流程 6
4.2 文献检索与候选排序 6
4.3 全文获取与其真实上限 7
4.4 LLM 抽取：合约化输出与鲁棒解析 8
4.5 幂等落库与断点续跑 8

5 数据质量治理 **8**
5.1 单位归一化 8
5.2 越界与离群检测 9
5.3 冲突消解：把分歧变成资产 10
5.4 评测设计 10

6 已完成工作的结果 **10**
6.1 流水线端到端功能验证 10
6.2 全文可获取性实测 10
6.3 抽取精度：占位 11

7 后续实验设计 **11**
7.1 Gold Set 标注与一致性 12
7.2 规模化抽取与人工抽检 12
7.3 建模实验：留一成员划分 12

8 数据合规与治理边界 **12**

9 结论与后续工作 **13**

A 复现命令 **15**

B 主要模块一览 **15**

1 引言

1.1 问题的由来：结晶数据” 可查” 但” 不可用”

半结晶性高分子（如聚对苯二甲酸乙二醇酯 PET、聚乳酸 PLA）的宏观性能几乎完全由结晶结构决定：晶型决定链构象与堆砌密度，晶胞参数反映链间相互作用，结晶度、片晶厚度与长周期决定力学与阻隔性能，而平衡熔点 T_m^0、熔融焓 ΔH_f、玻璃化转变温度 T_g 等热力学量则是加工窗口的直接依据。经典的 Hoffman–Weeks 外推 [4] 与 Lauritzen–Hoffman 折叠链理论 [5] 提供了把这些量联系起来的框架，其应用前提是**同类可比的数据序列**：同一聚合物、在明确的结晶温度 T_c 下、由确定的热历史得到的结构与热力学测量。

问题在于，这样的序列在文献中是**隐式存在、显式缺失**的。以 PET 为例，其晶胞参数早在 1954 年即由 Daubeny、Bunn 与 Brown 测定 [1]，此后数十年间不同作者在不同取向、不同结晶条件下给出过略有差异的晶胞；PLLA 的 α 晶型结构在 2001 年得到系统修正 [2]；PBT（早期文献称 PTMT）的三斜晶胞见 Mencik 的工作 [3]。这些数值分散在各自的论文表格里，单位不一（Å 与 nm、kJ/mol 与 J/g 混用），条件记录不完整（T_c、降温速率、拉伸比常常缺省），且彼此之间的不一致从未被系统整理。对研究者而言，这些数据” 可查”（能找到原文），但” 不可用”（无法直接汇总、比较与建模）。

1.2 为什么是” 一类高分子”，而不是” 所有高分子” 或” 单一聚合物”

构建此类数据库时，范围的选择决定了它能否产出科学结论。**面向” 所有高分子”** 看似野心更大，实则统计上无效：聚乙烯、PET、尼龙 6、纤维素、聚偏氟乙烯的重复单元化学结构差异远大于相似性，把它们放在同一个样本池里训练迁移模型，模型只能” 跑通”，无法给出可解释的结论；且若样本总量只有数百条，摊到数十个成员后每个成员仅十余条，采样密度不足以填充” 结晶条件 × 结构” 的交叉表。

面向” 单一聚合物” 则走向另一个极端：单一成员的数据量足以支撑细致分析，但结论无法外推，难以区分” 聚合物的个性” 与” 聚酯家族的共性”，也不足以支撑跨成员的构效关系讨论与留一成员（leave-one-polymer-out）泛化评测。

因此本文采用**家族口径**：聚焦半结晶性**聚酯家族**的 12 个成员（表 2）。选择聚酯的理由有三：

(1) **结构同源性**：重复单元均为酯键连接的二醇–二酸（或羟基酸）序列，主链化学结构可通过亚甲基数与芳环数两个整数参数化，成员之间存在可比较的同源序列；

(2) **性质跨度大**：从芳香族刚性链（PET、PEN）到脂肪族柔性链（PCL、PBS、PHB），T_g 与 T_m 跨度足以形成有意义的对照，且包含 $\alpha/\beta/\alpha'$ 等多晶型现象；

(3) **文献与产业基础**：聚酯既是产量最大的工程塑料/纤维品类之一，也是可降解塑料（PLA、PBS、PBSA、PHB、PHBV）的主体，文献积累跨越 70 年，数据密度高。

1.3 本文的贡献与边界

本文报告的是该数据库建设项目的**数据工程与方法学部分**，核心贡献为：

- 提出适配高分子结晶数据的四层数据模型（L0–L3），明确” 晶胞属晶型层、条件与热力学属观测层” 的划分原则（第 3 节）；

- 实现一条可断点续跑、幂等落库、具备置信自评与出处定位的 LLM 抽取流水线（第 4 节）；
- 针对高分子文献的单位陷阱与文献间数值分歧，给出归一化、越界检测与冲突消解的工程方案（第 5 节）；
- 以可复现的抽样实测量化” 自动化全文获取” 的真实上限，为同类项目提供可行性基线（第 6 节）；
- 明确一套可执行的数据合规边界，使数据库在开源与发表时具备清晰的版权立场（第 8 节）。

本文的结果边界（请读者注意）

截至本文撰写时，人工金标准（Gold Set）标注尚未完成，规模化抽取尚未执行，因此**本文不包含抽取精度、数据库规模等方面的实验数值**。凡涉及此类结果之处，均以明确标注的**占位表**呈现（表 6），待相应阶段完成后填入。本文可复现的定量结果限于：文献检索覆盖统计（4.2 节）、全文可获取性实测（4.3 节）、以及流水线端到端的功能验证（4 节）。

2　相关工作

2.1　通用材料数据库：晶体学与计算数据

晶体学领域已建成成熟的开放基础设施。Crystallography Open Database（COD）[6, 7] 以开放许可汇集数十万条无机/小分子晶体结构；Cambridge Structural Database（CSD）[8] 覆盖有机与金属有机小分子晶体；Materials Project[9] 则以第一性原理计算为主，提供无机材料的结构与能量学数据。这类资源的共同特点是**以完整晶体结构文件（CIF）为中心**，其数据质量由” 结构是否已解出” 这一硬门槛保证。

然而它们对**高分子结晶**覆盖极为有限。原因并非疏忽，而是本质困难：高分子晶体多为半结晶、链折叠、取向织构，通常只能得到纤维图或粉末图的**部分**结构信息，很少能满足 CIF 所需的全原子坐标与精修指标；即使已发表，也多以” 晶胞参数 + 链构象” 的表格形式存在于论文中，而非以结构文件形式沉淀。因此，**高分子结晶数据的入口是文献表格，而不是晶体学数据库**——这正是本文工作的出发点。

2.2　聚合物数据库：PoLyInfo 与其可复用性

日本物质材料研究机构（NIMS）的 PoLyInfo[10, 11] 是目前覆盖最广的聚合物数据库，收录均聚物、共聚物、混合物与复合材料的物性数据，并持续推进知识的机器可读标准化。PoLyInfo 证明了聚合物数据整合的价值，也揭示了两点局限：其一，其数据以**聚合物/牌号**为单位聚合，侧重工程物性，**结晶条件** → **结构** → **性质**的三联关系表达较弱；其二，其采用注册制并受版权约束，第三方既不能整包抓取，也不能直接再分发其内容。

这决定了本文的立场：PoLyInfo 在本项目中**仅用于交叉校验**，不作为数据来源入库；本文数据库坚持” 每一条数值都可回溯到单一公开 DOI”，从而保证开源与发表时的合规清晰性（详见 8 节）。

2.3 文献信息抽取：从规则工具到大语言模型

化学领域的自动抽取长期依赖规则与词典方法，代表性工作如 ChemDataExtractor[12] 提供化学命名实体识别与属性关系抽取。这类方法在命名实体上表现稳定，但对**跨句的条件—数值绑定**（例如” 在 $T_c = 180\,^{\circ}\mathrm{C}$ 结晶 2 h 后测得 $a = 4.56$ Å” 中，数值与条件的依存关系）以及表格的多样排版缺乏鲁棒性。

大语言模型的出现显著改变了这一局面。近期研究表明，LLM 可从材料科学文献表格中抽取知识图谱 [14]，可从特定领域的文献语料中完成知识发现 [15]，经微调后在化学文本挖掘任务上进一步提升 [16]，并已被用于构建领域数据库的自动化流程 [17]。聚合物信息学方面，机器学习模型的基准评测也已展开 [13]，但这类工作普遍指出：**数据规模与数据质量是比模型选择更强的瓶颈。**

本文的定位正处在这一缺口上：不追求提出新的抽取模型，而是把 LLM 作为可替换的抽取后端，重点解决” 抽取之后” 的工程问题——单位归一、越界检测、冲突消解、可溯源性——并给出可评测、可复现的流水线设计。

3 四层数据模型

3.1 分层原则

数据模型的设计原则只有一条：**让” 一条记录” 对应一个可被统计的观测单元，并让该单元的所有上下文都能被追溯。**据此建立四层结构（表 1）。

表 1: 四层数据模型（对应 schema v1.1 的 7 张表）

层	表	语义	典型字段
L0	`polymers`	聚合物成员（身份层）	缩写、中英文名、家族分支、重复单元分子量、手性、立构策略、Tier
L1	`polymorphs`	晶型与晶胞（结构层）	晶型标签、晶系、空间群、$a/b/c$、$\alpha/\beta/\gamma$、z、ρ_c、纤维周期、链构象
L2	`observations`	一次实测（观测层）	溯源 DOI、T_c、结晶路径、降温速率、退火、拉伸比、结晶度、长周期、T_m、T_m^0、ΔH_f、T_g、Avrami 指数、生长速率
L2.5	`atomic_coordinates` / `properties`	扩展（预留）	全原子坐标；未列入 L2 的其它实测量
L3	`literature_sources`	文献与抽取溯源	DOI、题录、抽取模型与版本、抽取时间、数值性事实片段

其中**最关键的一条约定**是：**晶胞参数属于 L1（晶型层），不在 L2 重复存储。**观测行通过

`polymorph_id` 外键引用晶型。这样设计的直接后果是，同一聚合物被不同文献给出的略有差异的晶胞不会被” 数值重复” 的去重规则误删，而是作为**多条晶型记录**共存，其分歧交由冲突消解模块显式管理（5.3 节）。

3.2 计数口径：一条 = 一个观测行

本文明确规定**计数单元为 L2 观测行**，而非论文篇数或聚合物个数：一篇论文若在 5 个不同 T_c 下给出 5 组结构/热力学数据，即产生 5 条观测。这是数据库能否支撑建模的关键设计——只有以观测行为单位，” 结晶条件 $\rightarrow$ 结构/性质” 的映射才具有足够的样本密度。项目规模化阶段的量化目标（≥ 300 条观测、覆盖 ≥ 8 个成员）即按此口径定义。

3.3 溯源是硬约束

L2 的每一条观测都必须携带 `doi`；`ref_source`（期刊/书名）、`ref_table`（原文表号或图号）与 `source_field`（`measured` / `review-cited`）用于区分**本文实测值**与**综述转引值**。后者在统计时须降权或单独分组，避免同一数值被多篇综述重复计入而放大权重。`extraction_confidence`、`reviewed_by`、`review_status` 三个字段共同构成质量标记，使” 机器抽取” 与” 人工核验” 的数据在库内始终可区分。

4 系统与方法

4.1 总体流程

流水线由 6 个可独立运行的阶段构成，各阶段之间以磁盘文件（JSON / SQLite）解耦，任何阶段失败均可从上一阶段的产物重入（图 1）。

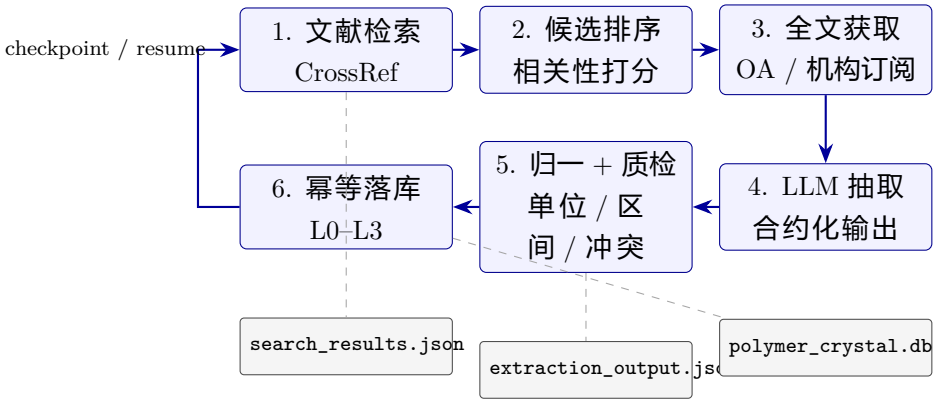


图 1: 抽取流水线总体流程。各阶段以磁盘产物解耦，支持断点续跑与单阶段重跑。

4.2 文献检索与候选排序

检索层使用 CrossRef REST API，按成员组织检索词（含同义词与历史称谓，例如 PBT 需同时检索 *poly(tetramethylene terephthalate)* 与缩写 PTMT；PLA 需覆盖 *poly(L-lactide)*），并加入晶型相关限定词。对返回结果按 DOI 去重后，所有请求均携带联系邮箱（mailto polite pool，即 CrossRef 官方建议的礼貌调用约定），保证服务可持续使用。

候选排序是本阶段的实际难点。直接用聚合物名做文本匹配会引入大量噪声：PDB 中大量"PET 降解酶" 的蛋白晶体结构、卟啉与金属配合物的小分子晶体学论文、以及与方法学相关的综述都会排在前列。为此实现了一个打分排序器，包含三条规则：(i) **身份词加权**——标题/摘要中出现聚合物身份词（*poly(...terephthalate)*、*polyester*、缩写等）显著加分；(ii) **缩写语境保护**——对 PET 等存在多义缩写的成员，要求缩写与高分子语境共现才计分，避免"positron emission tomography" 之类误召回；(iii) **剔除补充材料**——过滤 `.s001` 之类的补充信息条目，它们通常是主文的附件，题录不完整且无独立摘要。

排序后的候选进入人工标注与抽取队列。截至本文撰写时，检索阶段共得到 **725** 条不重复候选，覆盖全部 12 个 Tier1 成员，年份跨度 1956–2026（中位数 2009），各成员分布见表 2。

表 2: 12 个 Tier1 聚酯成员的检索覆盖（不重复 DOI）

缩写	中文名	篇数	分支	缩写	中文名	篇数	分支
PET	聚对苯二甲酸乙二醇酯	60	芳香族	PCL	聚己内酯	50	脂肪族
PBT	聚对苯二甲酸丁二醇酯	79	芳香族	PGA	聚乙醇酸	50	脂肪族
PTT	聚对苯二甲酸丙二醇酯	87	芳香族	PBS	聚丁二酸丁二醇酯	60	脂肪族
PEN	聚萘二甲酸乙二醇酯	60	芳香族	PBSA	聚 (丁二酸/己二酸丁二醇酯)	40	共聚酯
PBN	聚萘二甲酸丁二醇酯	50	芳香族	PHB	聚羟基丁酸酯	50	脂肪族
PLA	聚乳酸	99	脂肪族	PHBV	聚 (羟基丁酸/羟基戊酸) 酯	40	共聚酯

合计 725 条；年份 1956–2026，中位数 2009。

4.3 全文获取与其真实上限

晶胞参数几乎不出现在摘要中，这是高分子结晶抽取区别于其它领域抽取任务的关键特征。若仅以摘要为抽取源，晶胞、链构象、Avrami 指数等字段的召回率将结构性偏低。因此流水线必须尽可能使用全文。

为此实现了两个模块：生产模块负责查询 Unpaywall、对合法开放获取版本取回 PDF 并以`%PDF` 魔数校验（避免把 HTML 落地页误当成 PDF）；测量模块则对样本做分层抽样统计，用于量化" 可自动化获取" 的比例。测量模块把 Unpaywall 的 `is_oa` 进一步拆分为三类：`oa_pdf`（给出 `url_for_pdf` 且实际取回内容为 PDF）、`oa_landing`（判定为 OA 但链接指向出版商落地页/HTML）、`closed`（无合法 OA 版本）。

为什么必须区分 is_oa 与" 可自动下载"

OA 状态与" 可自动化下载" 并不等价。大量绿色 OA（仓储自存档）与金色 OA 条目在元数据中 `is_oa=true`，但其 `url` 指向的是 DOI 落地页或需会话的阅读器页面，程序化请求返回的是 HTML 而非 PDF。若只看 `is_oa`，会显著高估自动化获取能力，进而误判项目规模化的可行性。

实测结果见 6 节。其方法论意义在于：**同类项目不应以" 自动抓取" 为规模化基础**，高校项目应尽早规划机构订阅访问与人工下载，并把人工核验成本计入项目工期。

4.4 LLM 抽取：合约化输出与鲁棒解析

抽取后端采用抽象接口，可切换云端 API、本地模型与 `mock` 后端（用于无密钥时的全流程联调）。关键设计不在模型选择，而在**输出合约**：

(1) **宁可空、不许编。**提示词明确要求：原文未给出的字段输出 `null`，严禁依据常识或"典型值"补全。这一条直接决定了数据库的可信度——一条编造的晶胞参数比十条缺失更难被发现。

(2) **置信自评。**要求模型对每个数值给出 0–1 的置信度；置信低于阈值（当前取 0.7）的字段在落库时被标记为 `pending_review`，不参与统计分析，等待人工复核。

(3) **出处定位。**要求输出数值所在的**表号/图号**，与 DOI 一起构成可回溯定位。

(4) **单位显式化。**要求模型同时输出数值与**原文单位**，由归一化模块统一换算，而不是让模型"顺便"换算（后者是量级错误的主要来源）。

(5) **条件绑定。**结晶温度、降温速率、退火条件必须与被测数值成对输出，避免只抽数值、丢条件。

解析层对模型返回做鲁棒处理：剥离代码块围栏、定位首个与末个花括号以取出 JSON 对象、按合约字段名映射到 schema 列名。映射失败的字段不丢弃，而是记入诊断信息，供迭代提示词时使用。

4.5 幂等落库与断点续跑

落库顺序为 L3(文献)→ L1(晶型)→ L2(观测),去重键为 `doi + polymer + polymorph_label + t_c`。同一 (DOI, T_c) 重复跑批只会更新而不会新增，这使得"补跑失败批次"与"换模型重跑"都是安全操作。流水线以 checkpoint 文件记录已处理 DOI，进程中断后可从断点继续。

5 数据质量治理

5.1 单位归一化

入库前所有数值必须换算到规范单位（表 3）。这一环节看似平凡，却是高分子文献抽取中**量级错误的最大来源。**

ΔH_f 的换算是本项目最具代表性的陷阱。文献中熔融焓常以 kJ/mol（每摩尔重复单元）给出，而数据库规范单位为 J/g，两者相差一个重复单元分子量 M：

$$\Delta H_f\ [\mathrm{J/g}] = \frac{\Delta H_f\ [\mathrm{kJ/mol}] \times 1000}{M\ [\mathrm{g/mol}]} \tag{1}$$

以 PET 为例，$M = 192.17$ g/mol，文献值 26.9 kJ/mol 对应 $26.9 \times 1000/192.17 = 139.98$ J/g。若忘记除以 M，将得到约 2.7×10^4 J/g 的荒谬值，误差达两个数量级。因此归一化模块在**缺少重复单元分子量时明确拒绝换算**并报错，而不是静默保留原值——"拒绝"比"猜测"更安全。该用例已固化为单元测试。

表 3: 规范单位与典型换算（节选）

字段	规范单位	常见输入单位	换算与陷阱
a, b, c, 纤维周期	Å	nm、pm	nm $\rightarrow$ Å 乘 10；注意长周期常用 nm 而晶胞用 Å，二者不可混用
α, β, γ	°	rad	乘 $180/\pi$
ρ_c	g/cm^3	kg/m^3、Mg/m^3	kg/m^3 $\rightarrow$ g/cm^3 除 1000；Mg/m^3 与 g/cm^3 等值
T_c, T_m, T_m^0, T_g	°C	K、°F	K 是**偏移**而非比例；°F 需 $(v-32)\times 5/9$
ΔH_f	J/g	kJ/mol、cal/g	**kJ/mol $\rightarrow$ J/g 必须除以重复单元分子量**（见正文）
生长速率	nm/s	μm/s、μm/min	时间单位与长度单位需同时换算
结晶度	%	小数	0.45 $\rightarrow$ 45

5.2 越界与离群检测

质检分两级（表 4）：

- **硬区间**：由物理意义确定的绝对边界，超出即判定为错误（如晶胞 a 不可能为 300 Å，结晶度不可能为 150%）。区间的设定留有余量，避免误伤真实极端值。
- **统计离群**：对同一聚合物同一字段，用中位数与中位数绝对偏差（MAD $= 1.4826\times\text{median}(|x_i-\tilde{x}|)$）计算稳健 z 分数，$|z|>3.5$ 且样本数 ≥ 4 时报告。采用中位数与 MAD 而非均值与标准差，是因为离群值本身会把均值与标准差带偏，导致” 漏检” 或” 整片误报”。

表 4: 硬区间示例与统计离群策略

字段	硬区间	统计离群	说明
a, b, c	0.3–60 Å	是	高分子晶胞轴长量级
ρ_c	0.8–2.0 g/cm^3	是	聚合物晶体密度的物理上下限
T_m	0–400 °C	是	聚酯熔点上限余量充足
T_c、退火温度	$-$50–350 °C	**否**	实验条件，见正文
结晶度	0–100 %	是	百分比制
z	1–16	是	每晶胞重复单元数

实验条件字段不做统计离群判定

T_c、退火温度、降温速率、拉伸比属于**研究者主动设定的自变量**，其取值分散是合法的实验设计而非错误。若对它们施加统计离群判定，一个设置 5 个温度点的系统实验会被整片误报为离群。因此这类字段只做硬区间检查（例如 $T_c = 999\,^\circ$C 仍是不可能的），不参与 MAD 判定。这一区分是在实际数据上踩坑后确立的规则。

5.3 冲突消解：把分歧变成资产

文献间数值不一致在高分子结晶领域是常态而非异常：不同样品分子量、不同热历史、不同精修方法都会导致差异。**若把这类差异当作"错误"去消除，就会销毁项目最有价值的信息。**本文的机制是：

(1) **全部保留。**冲突的观测行一条也不删。

(2) **互相标记。**冲突双方均置 `conflict_flag=1`，并在 `clash_with_ids` 中互写对方 `obs_id`，使冲突关系双向可查。

(3) **分歧值入扩展表。**相对偏差超过容差(当前取 2%)的数值以键值对形式写入 L2.5 的 `properties` 表，保留"谁给了什么值"。

(4) **择优排序外置。**给出一个推荐排序（例如优先实测而非综述转引、优先高置信、优先近期且方法明确者），但**不覆盖、不删除**任何一条；使用者可在查询时按排序取首选值，也可取全部值做敏感性分析。

(5) **量级错误识别。**若两个值相差恰好约 10^n 倍（$n = 1, 2, 3$），优先判定为**单位错误**而非真实分歧，交由归一化模块复核，这类"假冲突"在实际数据中最常见（如 ρ_c 的 $1455\ \mathrm{kg/m^3}$ 与 $1.455\ \mathrm{g/cm^3}$）。

5.4 评测设计

评测以人工标注的 Gold Set 为基准，做**字段级**精确率/召回率/F_1，而非整条记录的匹配：

$$P = \frac{TP}{TP + FP}, \qquad R = \frac{TP}{TP + FN}, \qquad F_1 = \frac{2PR}{P + R} \tag{2}$$

其中 TP 为"抽对且值在容差内"的字段数，FP 为"抽了但错/原文没有却编造"的字段数，FN 为"原文有但没抽到"的字段数。Gold Set 中标注为 `null` 的字段视为中性，不计入 FN，以避免"原文确实没有该数据"被算作抽取失败。项目验收阈值设定为字段级 $F_1 \geq 80\%$。

6 已完成工作的结果

6.1 流水线端到端功能验证

在缺少云端密钥的条件下，流水线以 `mock` 后端完成端到端验证：检索 $\rightarrow$ 排序 $\rightarrow$ 抽取 $\rightarrow$ 归一 $\rightarrow$ 落库 $\rightarrow$ 评测六阶段全部跑通；重复跑批验证幂等性（同一 (DOI, T_c) 不产生重复行）；单位换算、越界检测、冲突消解三个模块在临时数据库副本上以合成数据验证：*(a)* 7 条观测的落库与关联正确；*(b)* 3 个超容差分歧值正确写入扩展表并置冲突标记；*(c)* 5 条记录正确互写 `clash_with_ids`；*(d)* $\rho_c = 1455$ 与 1.455 被正确识别为相差 10^3 倍的单位错误而非真实分歧。这些验证**只证明系统功能正确**，不构成抽取精度的证据。

6.2 全文可获取性实测

对 12 个成员各取前 5 条高相关候选（共 60 条）做分层抽样，逐条查询 Unpaywall，并对给出 `url_for_pdf` 的条目实际取回前 2 KB 以`%PDF` 魔数校验。结果见表 5。

三个数字值得注意。第一，**封闭访问的占 81.7%**（49/60），即绝大多数目标文献必须通过机构订阅或馆际互借获取。第二，判定为开放获取的 11 条（18.3%）中，只有 **2 条能由程序直接取回 PDF**，其余 9 条的链接指向出版商落地页或预印本平台的 HTML 页面。**若仅依据 Unpaywall 的 `is_oa` 字段评估可行性，会把自动化获取能力高估约 5.5 倍**（18.3% 对 3.3%）。第三，这 2 条可自动下载的全文，其主题分别为环状聚己内酯共聚物的合成与聚己内酯的生物降解性评价，**均不属晶胞测定类论文**；换言之，对本项目最需要的晶胞与链构象数据，本次抽样中可自动获取全文的比例实际为 0。这一结果提示：全文可获取性与字段可抽性是两个独立的瓶颈，需分别度量、分别解决。

表 5: 全文可获取性分层抽样实测（12 个成员分层抽样，每成员取前 5 条高相关候选，共 $n = 60$）

状态	条数	占比	含义
`closed`	49	81.7%	无合法开放获取版本，须机构订阅 / 馆际互借 / 人工获取
`oa_landing`	9	15.0%	判定为 OA，但链接为出版商落地页或 HTML，无法自动下载
`oa_pdf`	2	3.3%	给出 `url_for_pdf` 且实际取回内容为 PDF，可自动下载

样本 60 条；Unpaywall 查询成功 60 条。判定为开放获取（`is_oa=true`）共 11 条（占查询成功样本 18.3%），其中可自动下载全文 PDF 的 2 条。

该结果对项目规划的含义

(1) **不能依赖自动抓取做规模化。**判定为开放获取的条目中，真正能由程序直接下载全文 PDF 的只是少数，其余 OA 链接指向出版商落地页，需浏览器会话或人工点击。(2) **必须尽早接入机构订阅。**高校图书馆已订阅的主要出版商数据库（本项目涉及的 Wiley、Elsevier、ACS 等）才是可行入口，或走馆际互借与人工下载。(3) **人工核验成本应显式计入工期**，而不是当作" 出了问题再说的兜底"。(4) 因此本项目的抽取队列允许" 摘要模式" 与" 全文模式" 并存：摘要模式用于 T_m、T_g 等常在摘要出现的字段，全文模式专攻晶胞与链构象等只在表格出现的字段，并对后者做人工优先处理。

6.3 抽取精度：占位

抽取精度评测依赖人工 Gold Set 标注（PET/PTT/PBT/PLA 各 5 条，共 20 条，每条由人工打开原文核对数值与表号）。**截至本文撰写时该标注尚未完成**，因此下表为**占位表**，用于固化评测口径，**表中不填任何未经实测的数值。**

占位表的读数规则

表中"–" 表示**未测量**，不是" 零" 也不是" 缺失"。在标注与真实抽取完成前，本文不对抽取精度作任何定量声明。评测脚本（`src/extraction/evaluate.py`）已就绪，Gold Set 标注完成后可直接产出该表数值，无需改动评测口径。

7 后续实验设计

为说明数据库建成后的用途，本节给出已规划但尚未执行的实验设计。

表 6: 字段级抽取精度（占位表，待 Gold Set 标注与真实抽取完成后填入）

字段组	精确率 P	召回率 R	F_1	样本字段数
晶胞参数（$a, b, c, \alpha, \beta, \gamma$）	–	–	–	–
晶型标识（晶系/空间群/晶型标签）	–	–	–	–
热力学（$T_m, T_m^0, T_g, \Delta H_f$）	–	–	–	–
结晶条件（T_c、降温速率、退火）	–	–	–	–
结晶度与动力学（结晶度、Avrami n、生长速率）	–	–	–	–
合计（字段级）	–	–	–	–

7.1 Gold Set 标注与一致性

20 条金标准由两名标注者独立完成，对不一致字段回到原文仲裁。除字段值外，记录**表号/图号**与" 是否为综述转引"，以便把标注一致性（Cohen's κ）与抽取精度分开报告——前者衡量任务定义是否清晰，后者衡量系统性能，混淆二者是这类评测的常见错误。

7.2 规模化抽取与人工抽检

规模化阶段按成员分批，每批完成后抽取 10% 做人工复核，重点检查两类错误：**幻觉**（原文无此值却给出数值）与**条件错配**（数值正确但挂到了错误的 T_c）。前者通过" 置信阈值 + 人工复核" 控制，后者通过" 要求输出表号" 来降低——可定位的数值比不可定位的数值更容易复核。

7.3 建模实验：留一成员划分

数据库的三个下游任务规划为：**T1** 分类（给定条件与结构特征预测晶型）、**T2** 回归（预测 T_m、结晶度等连续量）、**T3** 语义检索（自然语言查询返回观测行）。评测采用**留一成员法**（leave-one-polymer-out，LOPO）：每次留出一个成员做测试，其余成员训练。若 LOPO 误差显著高于随机划分误差，即说明**该数据量下跨成员泛化不可行**，此时应诚实报告这一结论，并把分析本身写入论文的方法讨论，而不是用随机划分的乐观数字掩盖泛化失败——这是小规模材料数据集最常见的评测陷阱。

8 数据合规与治理边界

数据型项目的风险往往不在技术而在合规。本文确立并已在工程上落实以下边界：

(1) **每条数据必须可回溯单一 DOI**，无 DOI 的数据不入库。

(2) **只存数值性事实与出处定位**（表号/图号），不整段复制原文、不复制图表。

(3) **不整包抓取第三方数据库。**PoLyInfo 等注册制资源仅用于交叉校验，其内容不入库、不再分发。

(4) **回避晶体学文件的再分发问题。**CCDC / COD 等来源的 CIF 下载即受其许可约束，本项目只收录**已公开发表于论文中**的数值，不转载结构文件。

(5) **全文 PDF 只存本地、不进版本库、不外传**（已由.gitignore 强制）。

(6) **文献题录一律以 CrossRef 实时核验为准。**项目早期曾发现" 凭记忆写下的经典文献 DOI" 全部指向无关论文，故此后所有 DOI 在写入代码或数据前均须经 CrossRef 核验题录。

(7) **金标准数值只能由人工打开原文填写。**自动生成脚本只允许填候选书目（标记为 `suggested`），绝不允许脚本或模型臆测晶胞与热力学数值。

对同行的建议

" 数据库开源" 常被当作项目的结题指标，但**绝不能为凑量放入受限来源的数据。**一篇因版权问题被撤的论文，对项目与作者的伤害远大于一个延迟发布的数据库。把合规边界写进代码（而非只写在文档里）是保证它被执行的有效方式。

9　结论与后续工作

本文面向半结晶性聚酯家族，给出了一个结晶数据库的数据模型、抽取流水线与质量治理方案。方法的要点可归纳为三句话：**以观测行为计数单元**，使结晶条件与结构/性质形成可统计的映射；**以晶型层承载晶胞**，使文献间分歧不被去重规则误删；**以保留分歧代替消除分歧**，把不一致转化为可分析的数据资产。工程上，单位归一化（尤其是 kJ/mol 与 J/g 的分子量依赖换算）、条件字段豁免统计离群判定、以及"OA 状态 $\neq$ 可自动下载" 的实测结论，是本项目在实践中确立的三条经验，对同类文献数据项目具有直接参考价值。

本文也明确划出了当前的能力边界：抽取精度尚未评测，规模化数据尚未入库。后续工作按三条线推进：(i) 完成 Gold Set 人工标注并产出字段级精度报告；(ii) 依托机构订阅完成规模化抽取，达成 ≥ 300 条观测、覆盖 ≥ 8 个成员的目标；(iii) 上线语义检索与留一成员评测，并公开数据库与流水线代码。

致谢

感谢南京大学有训书院「金种子项目」早期科研训练计划的支持，感谢胡文兵老师在聚酯结晶物理方面的指导与对数据口径的把关。感谢 NIMS PoLyInfo 提供的交叉校验渠道，以及 CrossRef、Unpaywall 提供的开放 API。

数据与代码可用性

本文涉及的流水线代码、数据库 schema、检索与质检脚本均在项目仓库中维护，运行方式见仓库 README。受版权约束的内容（全文 PDF、第三方数据库内容）不在公开范围内。

参考文献

[1] Daubeny R de P, Bunn C W, Brown C J. The crystal structure of polyethylene terephthalate[J]. *Proceedings of the Royal Society of London Series A*, 1954, 226: 531–542. DOI: 10.1098/rspa.1954.0273

[2] Alemán C, Lotz B, Puiggali J. Crystal structure of the α-form of poly(L-lactide)[J]. *Macromolecules*, 2001, 34(14): 4795–4801. DOI: 10.1021/ma001630o

[3] Mencik Z. The crystal structure of poly(tetramethylene terephthalate)[J]. *Journal of Polymer Science: Polymer Physics Edition*, 1975, 13(11): 2173–2181. DOI: 10.1002/pol.1975.180131109

[4] Hoffman J D, Weeks J J. Melting process and the equilibrium melting temperature of polychlorotrifluoroethylene[J]. *Journal of Research of the National Bureau of Standards Section A*, 1962, 66A: 13. DOI: 10.6028/jres.066a.003

[5] Lauritzen J I, Hoffman J D. Theory of formation of polymer crystals with folded chains in dilute solution[J]. *Journal of Research of the National Bureau of Standards Section A*, 1960, 64A: 73. DOI: 10.6028/jres.064a.007

[6] Gražulis S, Chateigner D, Downs R T, et al. Crystallography Open Database—an open-access collection of crystal structures[J]. *Journal of Applied Crystallography*, 2009, 42(4): 726–729. DOI: 10.1107/s0021889809016690

[7] Gražulis S, Daškevič A, Merkys A, et al. Crystallography Open Database (COD): an open-access collection of crystal structures and platform for world-wide collaboration[J]. *Nucleic Acids Research*, 2012, 40(D1): D420–D427. DOI: 10.1093/nar/gkr900

[8] Groom C R, Bruno I J, Lightfoot M P, Ward S C. The Cambridge Structural Database[J]. *Acta Crystallographica Section B*, 2016, 72(2): 171–179. DOI: 10.1107/s2052520616003954

[9] Jain A, Ong S P, Hautier G, et al. Commentary: The Materials Project: a materials genome approach to accelerating materials innovation[J]. *APL Materials*, 2013, 1(1): 011002. DOI: 10.1063/1.4812323

[10] Otsuka S, Kuwajima I, Hosoya J, et al. PoLyInfo: polymer database for polymeric materials design[C]//*2011 International Conference on Emerging Intelligent Data and Web Technologies*. IEEE, 2011: 22–29. DOI: 10.1109/eidwt.2011.13

[11] Ishii M, Ito T, Sakamoto K. NIMS polymer database PoLyInfo (II): machine-readable standardization of polymer knowledge expression[J]. *Science and Technology of Advanced Materials: Methods*, 2024, 4(1): 2354651. DOI: 10.1080/27660400.2024.2354651

[12] Swain M C, Cole J M. ChemDataExtractor: a toolkit for automated extraction of chemical information from the scientific literature[J]. *Journal of Chemical Information and Modeling*, 2016, 56(10): 1894–1904. DOI: 10.1021/acs.jcim.6b00207

[13] Tao L, Varshney V, Li Y. Benchmarking machine learning models for polymer informatics: an example of glass transition temperature[J]. *Journal of Chemical Information and Modeling*, 2021, 61(11): 5395–5413. DOI: 10.1021/acs.jcim.1c01031

[14] Dreger M, Malek K, Eikerling M. Large language models for knowledge graph extraction from tables in materials science[J]. *Digital Discovery*, 2025, 4: 1221–1231. DOI: 10.1039/d4dd00362d

[15] Su Y, Yang S, Liu Y, et al. Knowledge discovery from porous organic cage literature using a large language model[J]. *Digital Discovery*, 2025, 4: 403–410. DOI: 10.1039/d4dd00337c

[16] Zhang W, Wang Q, Kong X, et al. Fine-tuning large language models for chemical text mining[J]. *Chemical Science*, 2024, 15: 10600–10611. DOI: 10.1039/d4sc00924j

[17] Itani S, Zhang Y, Zang J. Large language model-driven database for thermoelectric materials[J]. *Computational Materials Science*, 2025, 253: 113855. DOI: 10.1016/j.commatsci.2025.113855

A 复现命令

```
# 1）初始化数据库（写入 12 个 Tier1 成员）
python src/database/init_db.py

# 2）文献检索（CrossRef，按成员分组，DOI 去重）
python -m src.extraction.literature_search

# 3）候选排序（剔除补充材料与小分子晶体学噪声）
python src/annotation/shortlist.py --polymers PET,PBT,PTT,PLA --top 10

# 4）全文可获取性测量（本文表 4 的复现方式）
python src/annotation/oa_survey.py --per-polymer 5

# 5）流水线端到端（无密钥时用 mock 后端）
python -m src.extraction.pipeline --backend mock --limit 10 --dry-run

# 6）单位 / 区间 / 冲突 的统一质检入口（含自测）
python -m src.extraction.qa --self-test
python -m src.extraction.qa            # 只报告
python -m src.extraction.qa --apply    # 写回冲突标记

# 7）字段级精度评测（Gold Set 标注完成后）
python -m src.extraction.evaluate --extracted data/processed/extraction_output.json
```

B 主要模块一览

表 7: 流水线模块与职责

模块	职责
`extraction/literature_search.py`	CrossRef 检索、DOI 去重、按成员落盘
`annotation/shortlist.py`	候选相关性打分排序；剔除补充材料与缩写误召回
`extraction/fetch_pdf.py`	合法 OA 全文获取；`%PDF` 魔数校验；人工清单生成
`annotation/oa_survey.py`	全文可获取性分层抽样测量（本文表 5）
`extraction/llm_client.py`	LLM 后端抽象（云端 / 本地 / mock）；退避与配额语义区分
`extraction/prompts.py`	输出合约与字段映射；” 宁可 null 不许编” 约束
`extraction/extractor.py`	JSON 鲁棒解析
`extraction/normalizer.py`	结构 (L1) / 实测 (L2) 拆分；低置信转人工复核
`extraction/units.py`	单位归一化；kJ/mol → J/g 的分子量依赖换算
`extraction/sanity.py`	硬区间 + 中位数/MAD 稳健离群；条件字段豁免
`extraction/conflict.py`	冲突检测、量级倍数识别、择优排序（不删除）
`extraction/store.py`	幂等落库（L3→L1→L2）；分歧值入扩展表
`extraction/pipeline.py`	编排、断点续跑、`--dry-run`
`extraction/evaluate.py`	Gold Set 字段级 $P/R/F_1$
`extraction/qa.py`	质检统一入口与自测
`annotation/gold_set_annotator.py`	金标准标注工具
`annotation/fetch_citations.py`	参考文献 DOI 的 CrossRef 题录核验